Большие языковые модели

Устройство, обучение и управление генерацией

Алан-Барсаг Газзаев

7 ноября 2026 · Блок 3

Содержание лекции

- Разберём, как модель оценивает продолжение текста и последовательно формирует ответ.
- Свяжем токенизацию, контекстное окно и устройство декодера с практическими ограничениями.
- Обсудим предобучение, обучение на инструкциях и основные семейства моделей.
- Сравним параметры генерации и выполнение задачи по примерам в контексте.

Задачи больших языковых моделей

Задача	Пример результата
Классификация	Категория обращения: «возврат средств»
Извлечение	Дата, сумма и номер заказа из сообщения
Преобразование	Перевод или краткое изложение документа
Генерация	Черновик ответа по заданным сведениям

- Один интерфейс генерации позволяет задавать разные форматы результата.
- Качество проверяют по требованиям конкретной задачи, а не только по связности текста.

Модель, диалог и приложение

Уровень	Что он делает
Языковая модель	Вычисляет оценки следующих токенов
Диалоговый формат	Обозначает роли и границы сообщений
Приложение	Хранит историю, вызывает поиск и инструменты

- Доступ к интернету, документам и календарю обеспечивается компонентами приложения.
- Текстовая команда сама по себе не означает выполнения действия во внешней системе.

Задача языкового моделирования

- Вход — последовательность уже известных токенов; выход — распределение возможных продолжений.
- Для каждой позиции модель использует доступный предшествующий контекст.
- При обучении правильное продолжение берётся из текста; при применении следующий токен выбирает алгоритм генерации.
- Высокая вероятность продолжения не является самостоятельной проверкой фактической истинности.

Подсказки следующего слова



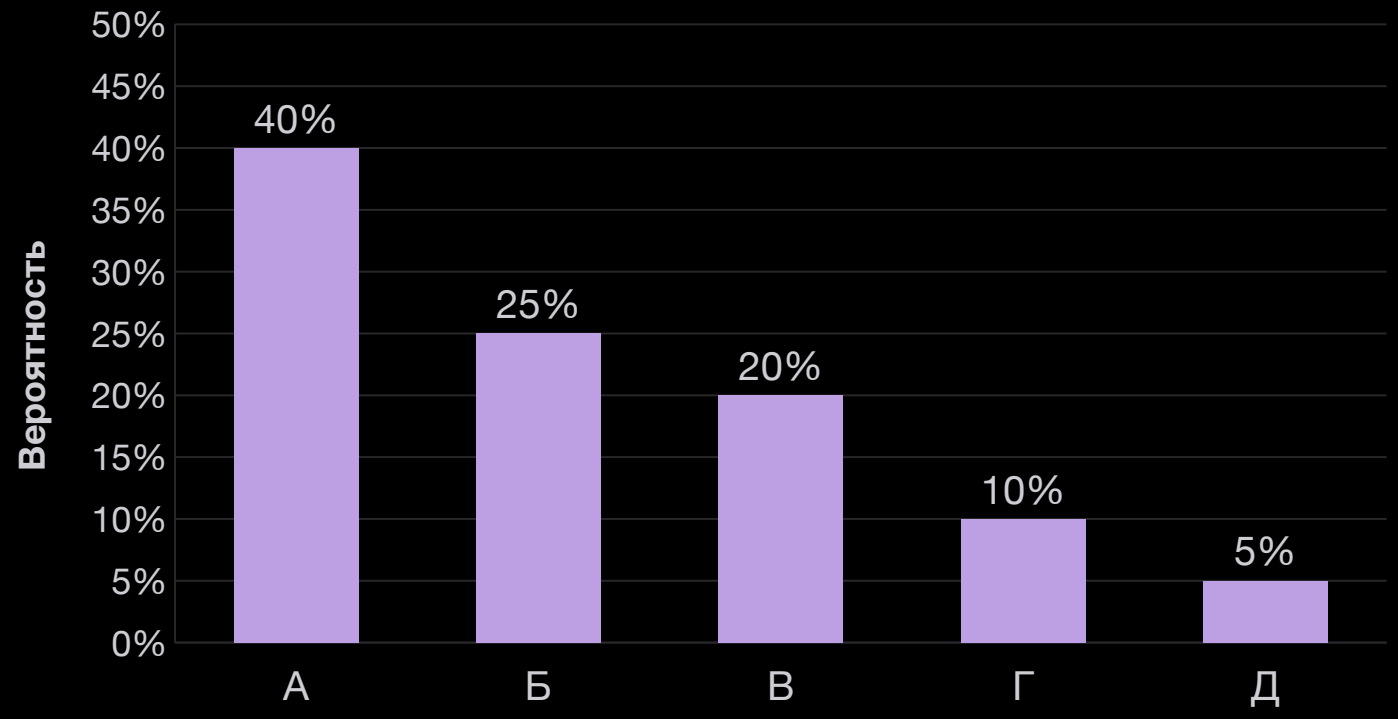
Клавиатура предлагает продолжения уже набранного текста. Языковая модель оценивает продолжение по контексту.

Сдвиг входа и целевой последовательности

Доступный контекст	Следующий элемент
Начало последовательности	Заказ
Заказ	будет
Заказ будет	доставлен
Заказ будет доставлен	завтра

- Один текст создаёт несколько задач предсказания с разным префиксом.
- Для наглядности здесь элементы совпадают со словами; реальная модель работает со своим токенизатором.

Распределение следующего токена



- Каждый кандидат получает вероятность при данном контексте.
- Распределение меняется после добавления каждого нового токена.
- На графике показан условный пример, а не измеренный вывод модели.

Последовательная генерация



- Выбранный токен добавляется к контексту; модель вычисляет новое распределение.
- Ответ зависит от всех предыдущих выбранных элементов.
- Процесс завершается по служебному токену или заданному ограничению.

Вероятность последовательности

$$P(x_1, \ldots, x_n) = \prod_t P(x_t \mid x_1, \ldots, x_{t-1})$$

- Вероятность полного продолжения раскладывается в произведение условных вероятностей.
- В вычислениях удобно суммировать логарифмы, чтобы работать с очень малыми числами.
- Наиболее вероятный токен на одном шаге не гарантирует наиболее вероятного полного продолжения.
- Сравнение последовательностей разной длины требует явно заданного критерия.

Завершение ответа

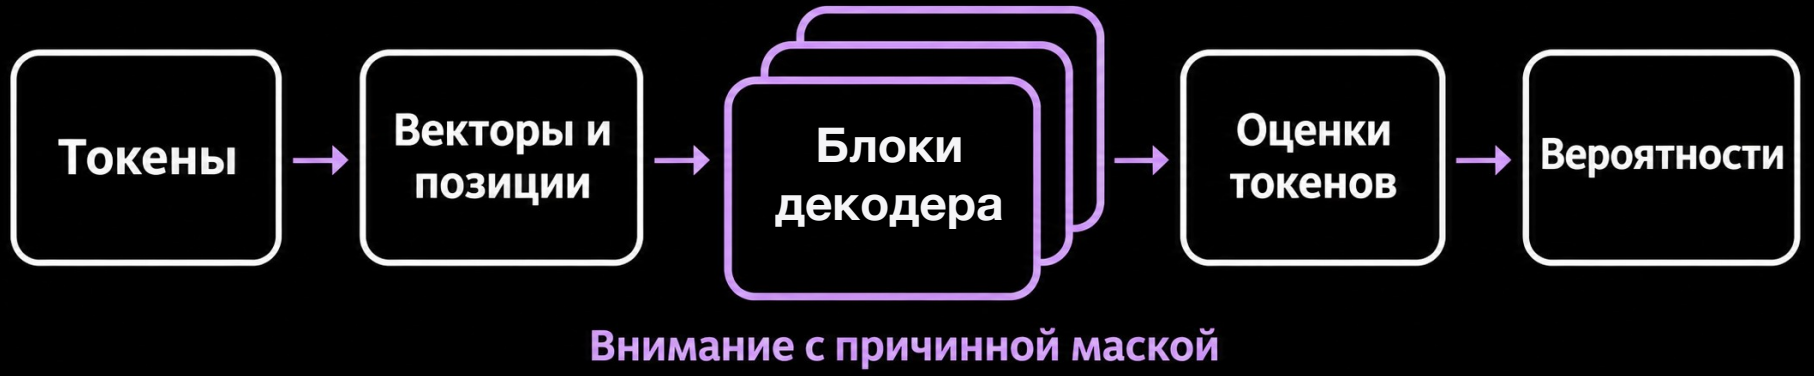
- Служебный токен завершения показывает, что модель выбрала конец последовательности или сообщения.
- Ограничение числа новых токенов останавливает вычисление даже при незавершённом предложении.
- Стоп-последовательности могут задаваться приложением, если используемый интерфейс их поддерживает.
- Причину остановки нужно отличать от качества ответа: короткий вывод может быть результатом лимита.

Три варианта архитектуры

Вариант	Доступ к контексту и применение
Кодировщик	Контекст с обеих сторон; признаки и анализ
Декодер	Предшествующие позиции; продолжение текста
Кодировщик и декодер	Обработка входа и генерация отдельного выхода

- BERT иллюстрирует кодировщик, семейство GPT — авторегрессионный декодер.
- Выбор архитектуры связан с обучающей задачей и форматом результата.

Основные части декодера



- Токены преобразуются в векторы с информацией о положении.
- Повторяющиеся блоки объединяют контекст и преобразуют представления позиций.
- Выходной слой вычисляет оценки по словарю возможных продолжений.

Причинная маска внимания

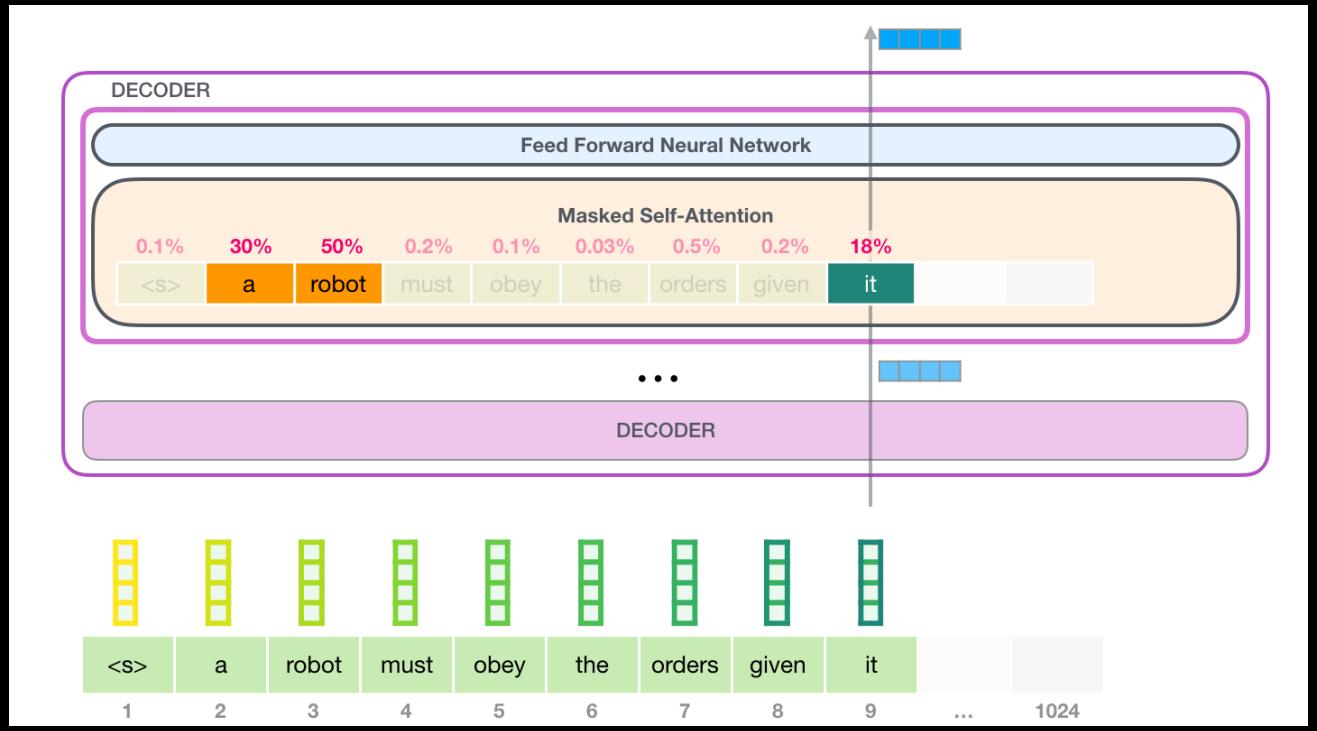
Позиция	1	2	3	4
1	✓	—	—	—
2	✓	✓	—	—
3	✓	✓	✓	—
4	✓	✓	✓	✓

- Строка показывает, какие позиции доступны текущему элементу.
- Будущие токены закрыты: иначе модель получила бы подсказку при обучении.
- Текущая позиция доступна; из её состояния предсказывается следующий токен.

Роль механизма внимания

- Представление позиции формируется с учётом полезной информации из доступного контекста.
- Механизм внимания позволяет связывать элементы, расположенные далеко друг от друга.
- Несколько голов дают разные обучаемые способы сопоставления позиций.
- Веса внимания не следует автоматически считать полным объяснением причин ответа модели.

Связи между словами

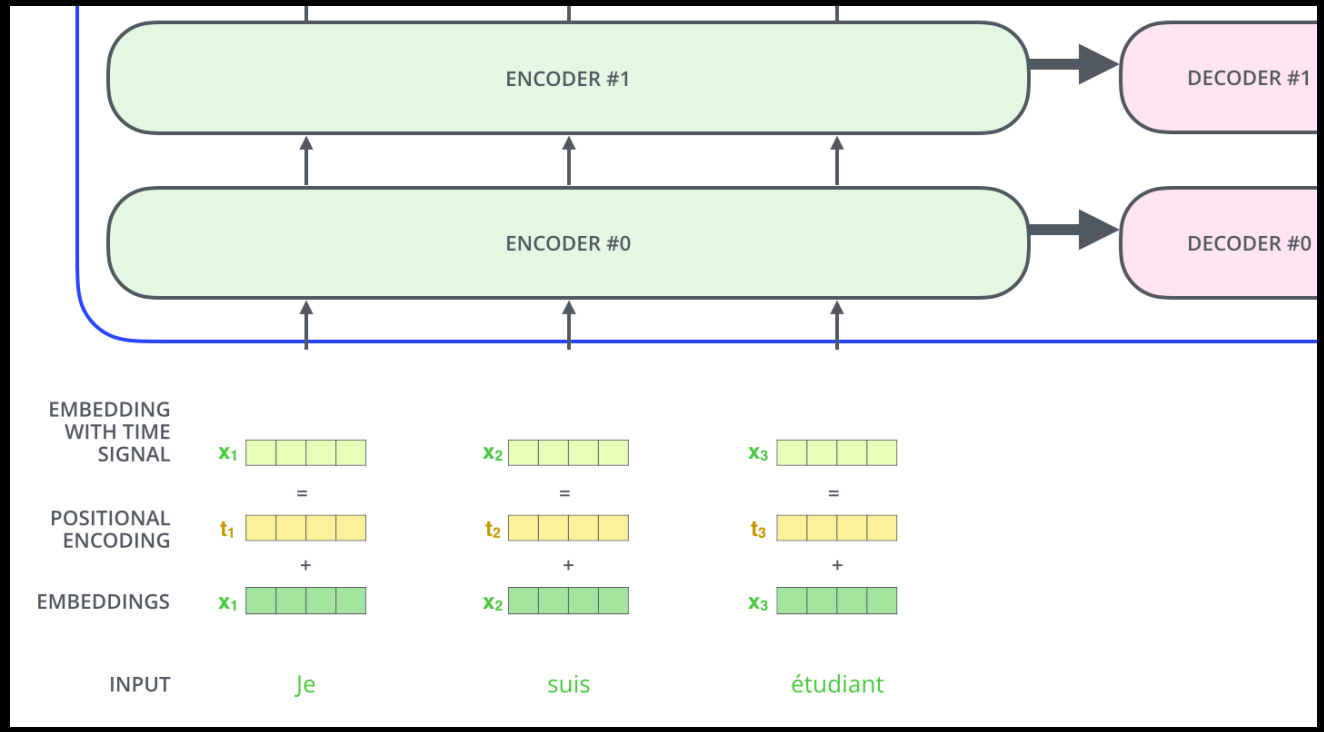


Выделенные связи показывают, к каким словам обращается механизм внимания при построении представления текущего токена.

Информация о порядке элементов

- Одного набора векторов токенов недостаточно, чтобы описать порядок последовательности.
- Модель получает позиционную информацию; конкретный способ зависит от архитектуры.
- Перестановка участников и отрицаний может изменить смысл при сохранении почти всех слов.
- Длинный контекст требует проверки: формально допустимая длина не гарантирует одинакового качества на всех позициях.

Вектор токена и его позиция



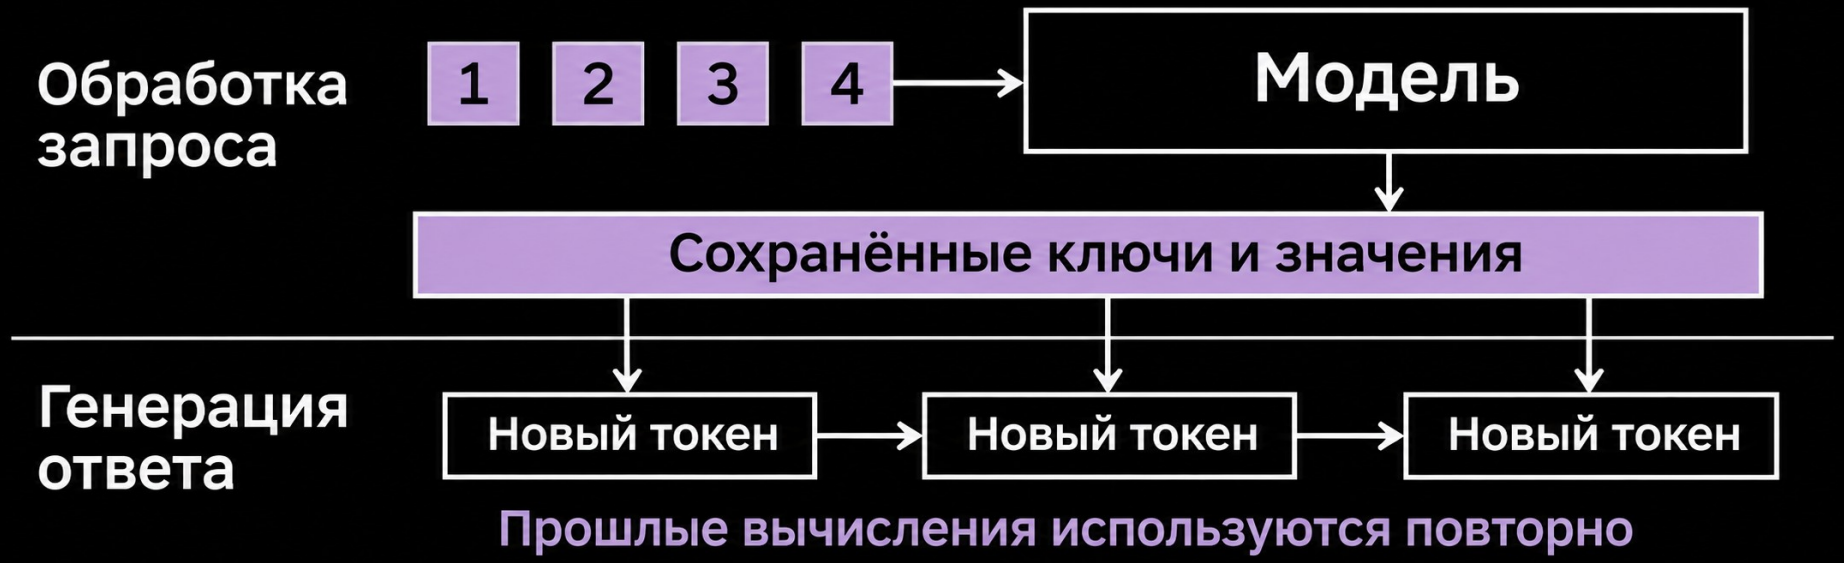
К представлению слова добавляют сведения о позиции. Схема иллюстрирует позиционное кодирование исходного Transformer.

Обучение и применение модели

Свойство	Обучение	Генерация
Продолжение	Известно из данных	Ещё не выбрано
Позиции	Много целей за проход	Зависимые шаги ответа
Параметры	Обновляются	Обычно фиксированы

- Причинная маска сохраняется даже при параллельной обработке обучающего текста.
- Последовательность ответа ограничивает обычную генерацию по времени.

Обработка запроса и продолжение

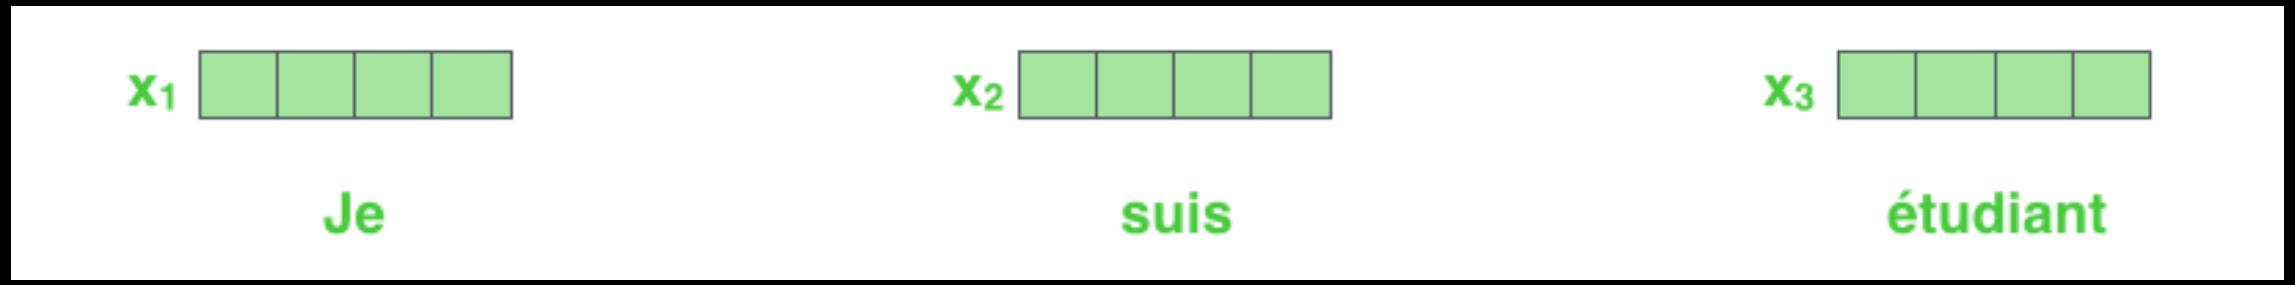


- Сначала модель обрабатывает входной контекст; затем добавляет токены ответа.
- Кеш ключей и значений позволяет повторно использовать часть предыдущих вычислений.
- Длинная история увеличивает объём хранимого состояния и стоимость работы.

Токены и словарь

- Токен может быть словом, частью слова, знаком или другой единицей выбранного разбиения.
- Словарь связывает единицы с числовыми идентификаторами.
- Идентификатор выбирает параметры представления; близкие номера не означают близкий смысл.
- Ограничения длины и стоимость обычно измеряются в токенах, а не в русских словах.

Преобразование текста в векторы



Каждый токен получает числовой вектор. Цветные столбцы на схеме обозначают представления токенов.

Пример разбиения русской фразы

Запись	Условное разбиение
Перенеси встречу	Пере | неси | встреч | у
07:30	07 | : | 30
новый_заказ	новый | _ | заказ

- Таблица иллюстрирует возможные границы; это не вывод конкретного токенизатора.
- При практической работе проверяют реальные идентификаторы и обратное восстановление текста.
- Граница токена не обязана совпадать с морфемой или пробелом.

Построение словаря из частей слов

- В методах семейства BPE частые сочетания базовых элементов постепенно объединяются.
- Частая запись может стать одной единицей, редкая — последовательностью нескольких известных частей.
- Размер словаря влияет на длину представления и число параметров таблицы токенов.
- Правила нормализации и работа с байтами зависят от реализации токенизатора.

Алгоритм и инструмент токенизации

Название	Что важно различать
BPE	Обучение словаря через объединения
WordPiece	Другой подход к словарю частей слов
SentencePiece	Инструмент с поддержкой BPE и Unigram

- Названия не обозначают три полностью одинаковых по уровню понятия.
- Модель ожидает конкретный словарь, нормализацию и набор служебных элементов.
- Совместимость массива по размеру не гарантирует правильного смысла индексов.

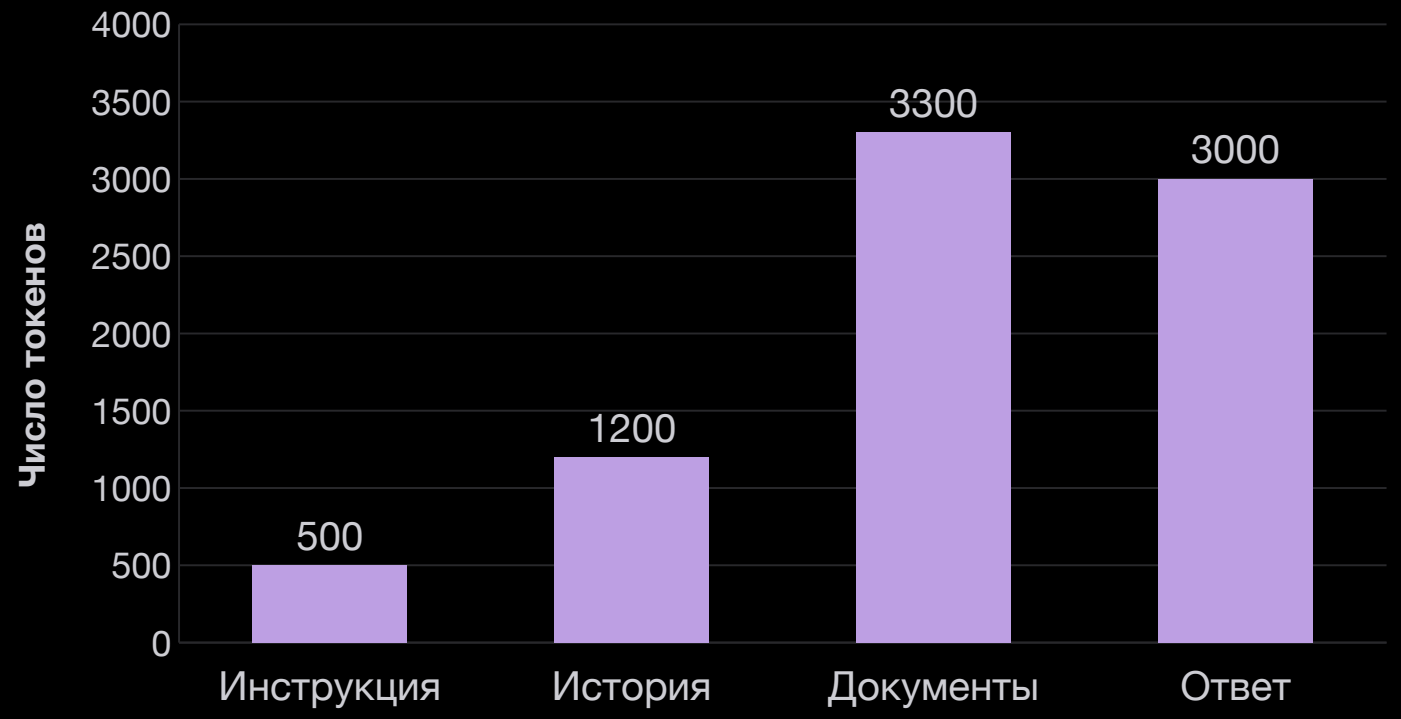
Токенизация разных языков

- Одинаковая по смыслу фраза на разных языках может иметь разную длину в токенах.
- Состав корпуса и словаря влияет на то, какие записи представлены целиком, а какие дробятся.
- Для русского языка важны словоформы, кириллица, сокращения и смешение алфавитов.
- Поддержку языка оценивают по реальным задачам, а не только по возможности закодировать строку.

Числа, имена и программный код

- Число, дата или идентификатор могут состоять из нескольких токенов.
- Небольшое изменение записи иногда меняет разбиение и характер ошибок.
- В задачах извлечения важно сохранять точные символы, единицы измерения и ведущие нули.
- Правильный формат ответа проверяют отдельно от правдоподобия его формулировки.

Распределение контекстного бюджета

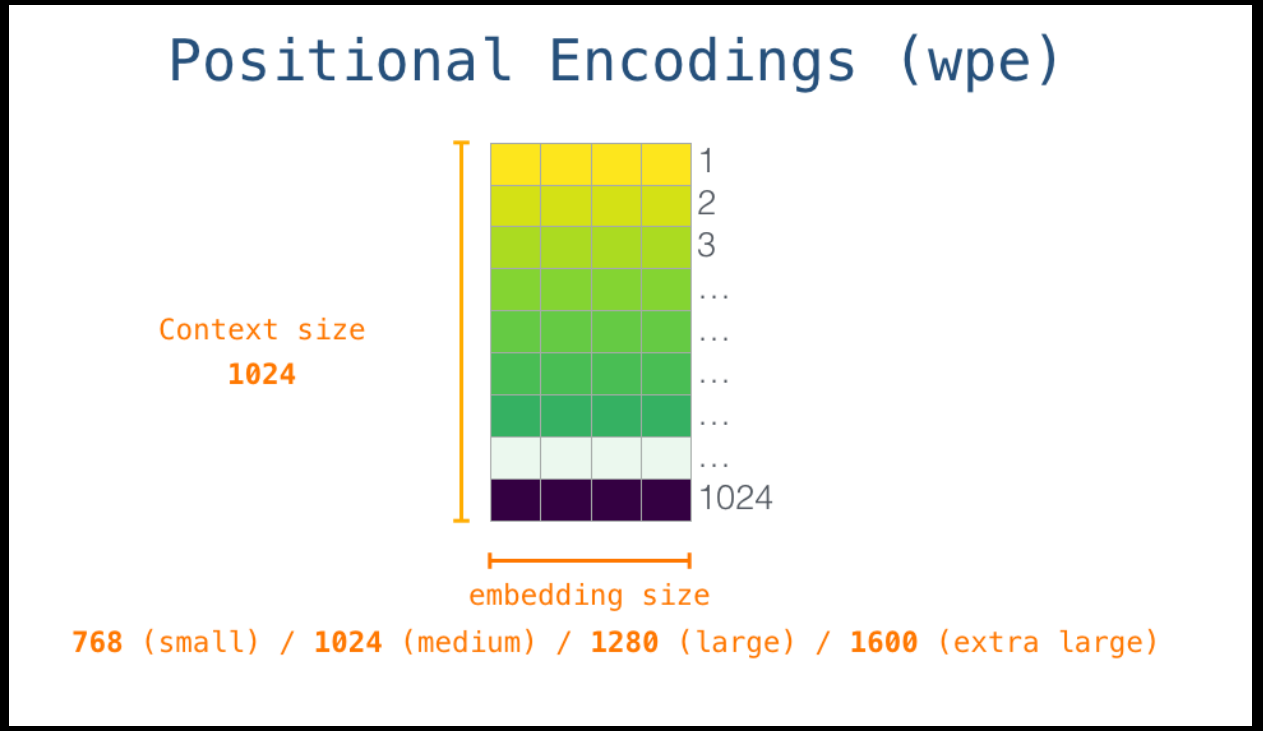


- Вход занимают инструкция, история диалога и дополнительные материалы.
- Для генерируемого ответа также нужен доступный бюджет.
- Пример на 8000 токенов условный; реальные лимиты задаёт конкретная модель и интерфейс.

Длинный контекст и обрезка

- При превышении лимита система должна отклонить вход, сократить его или разбить обработку на этапы.
- Обрезка способна удалить условие, исключение или сведения из начала диалога.
- Даже помещающийся текст не гарантирует одинакового использования информации на всех позициях.
- Полезность длинного контекста проверяют на вопросах, требующих конкретных фактов из него.

Таблица позиционных представлений



Исторический пример GPT-2: 1024 позиции. Строки соответствуют позициям, столбцы — координатам вектора; это не общий лимит всех моделей.

Обучающая цель и функция потерь

$$L = -(1/N) \sum_t \log P\theta(x_t \mid x<t)$$

- Модель получает штраф, если присваивает наблюдаемому продолжению низкую вероятность.
- Оптимизация изменяет параметры θ на множестве обучающих последовательностей.
- Снижение средней потери показывает успех на этой цели, но не заменяет проверку прикладных задач.
- Редкие случаи и фактические ошибки могут сохраняться при хорошем среднем значении.

Подготовка обучающей коллекции

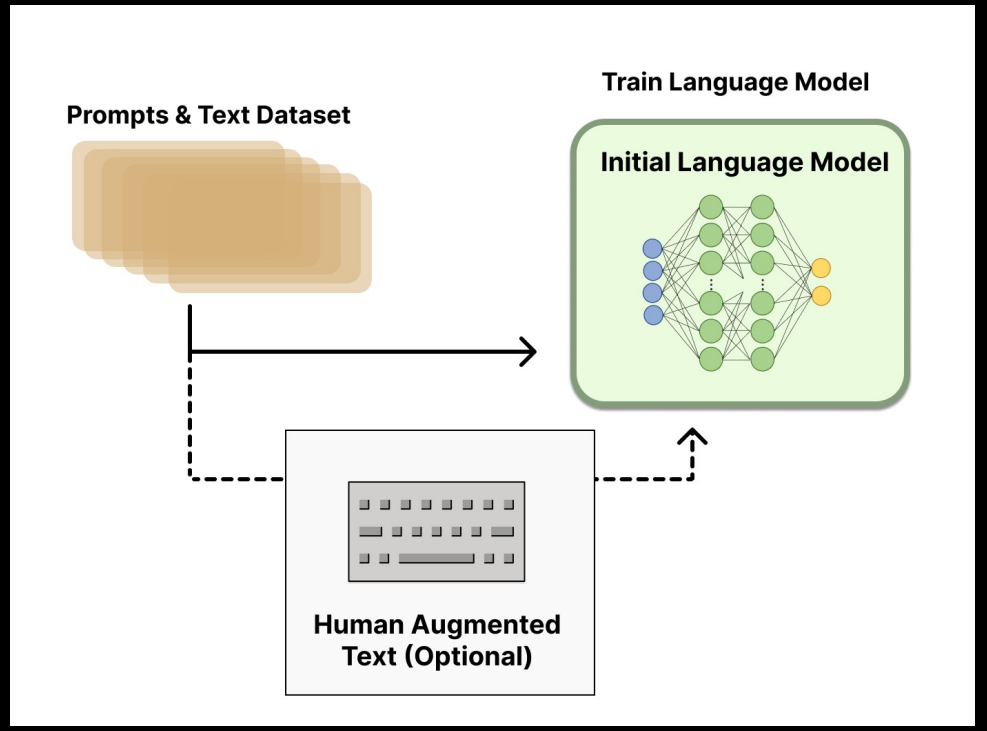


- Корпус может включать документы, диалоги, программный код и другие разрешённые источники.
- Очистка и устранение повторов меняют качество обучающего сигнала.
- Состав коллекции влияет на язык, стиль и предметные знания модели.

Качество данных и независимая оценка

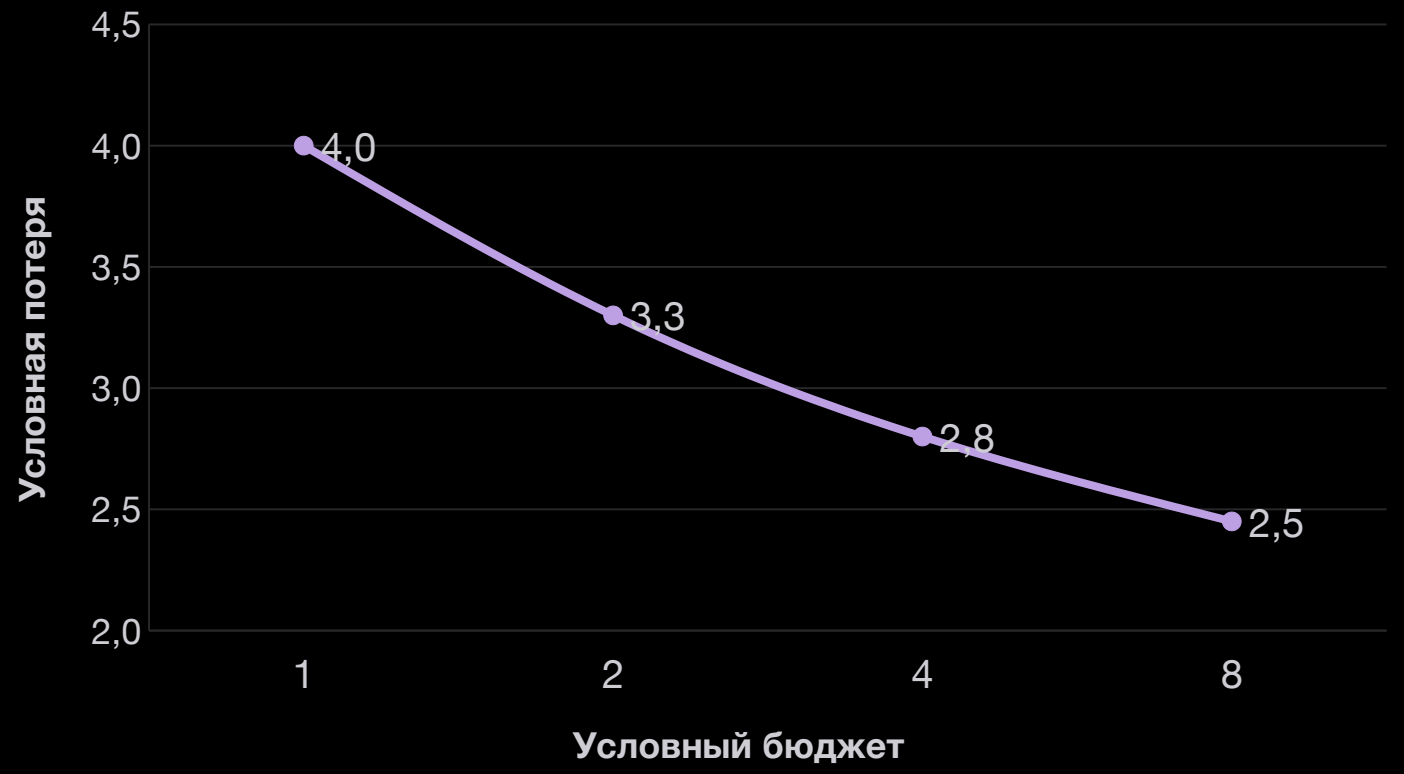
- Повторы усиливают одни наблюдения, не обязательно добавляя новые языковые ситуации.
- Ошибки, противоречия и смещения корпуса могут переноситься в ответы модели.
- Попадание тестовых заданий в обучение затрудняет оценку способности работать на новых задачах.
- Прикладной набор проверок должен соответствовать языку, области и условиям использования.

Данные для обучения языковой модели



Корпус текста используют для обучения модели. Качество и состав корпуса определяют, какие закономерности она может усвоить.

Закономерности масштабирования

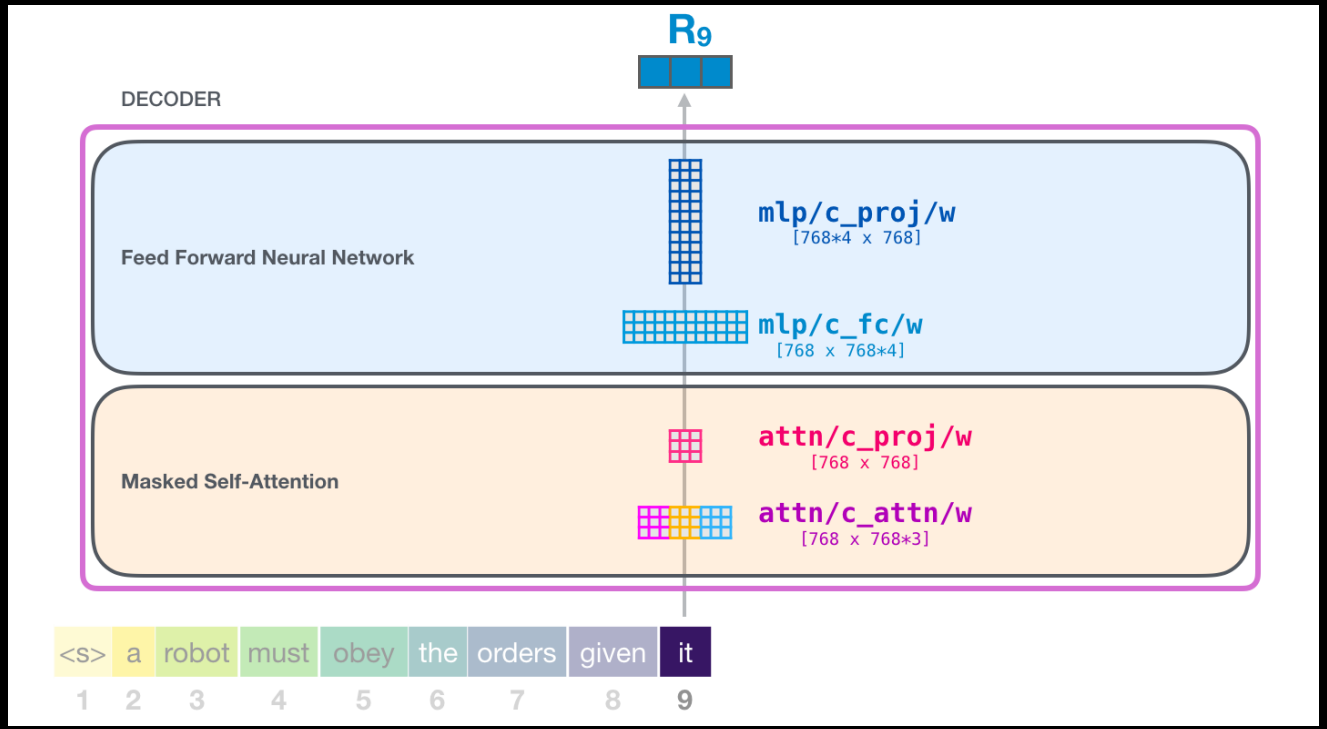


- В исследованиях средняя потеря связана с размером модели, объёмом данных и вычислениями.
- Эмпирическая зависимость действует в определённых условиях и не обещает решения любой задачи.
- График схематический: условные значения показывают направление, а не результаты эксперимента.

Параметры, данные и вычисления

- Параметры определяют ёмкость и затраты хранения; данные задают доступные обучающие наблюдения.
- При фиксированном бюджете увеличение модели уменьшает ресурсы, доступные на обработку данных.
- Исследования вычислительно эффективного обучения рассматривают совместный выбор масштаба модели и корпуса.
- Стоимость применения также важна: большая модель может быть слишком медленной для конкретного сервиса.

Где находятся обучаемые параметры



Матрицы весов в блоке GPT-2 задают преобразования представлений. Число параметров и объём вычислений связаны, но не совпадают.

Базовая и инструктивная модель

Вариант	Учебная цель и ожидаемое поведение
Базовая	Продолжать текст по языковым закономерностям
Инструктивная	Выполнять запросы в показанном формате
Диалоговая	Работать с последовательностью сообщений

- Инструктивные и диалоговые свойства могут сочетаться в одной модели.
- Формат запроса должен соответствовать варианту и его шаблону сообщений.
- Следование инструкции не является гарантией фактической правильности.

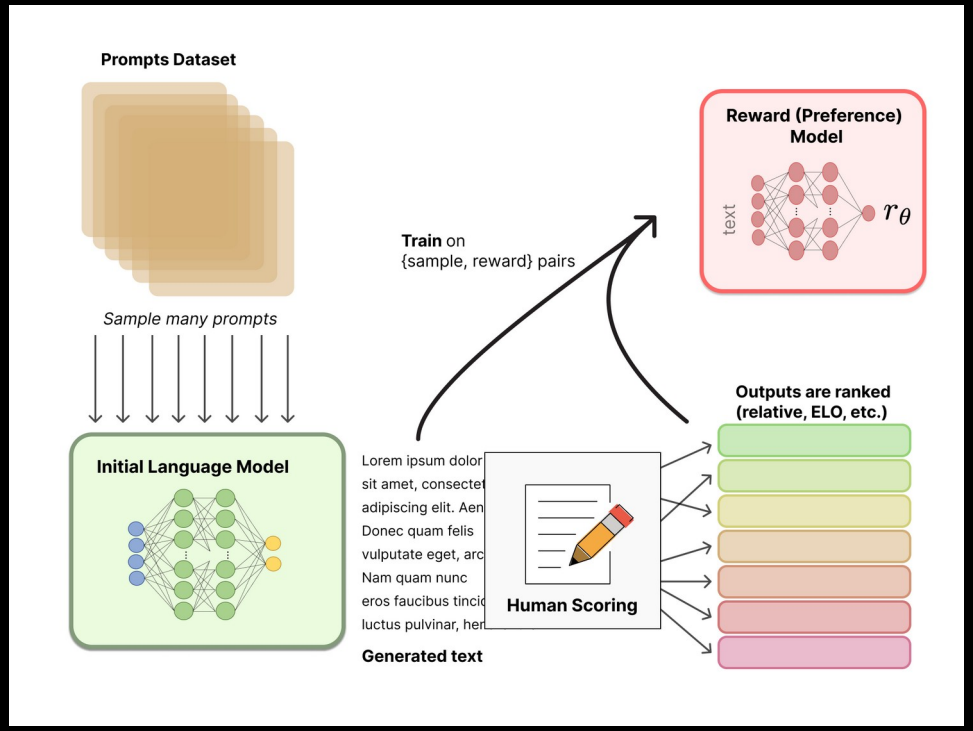
Обучение на инструкциях

- Обучающие примеры связывают запрос, доступный контекст и желаемый ответ.
- Модель учится выдавать полезную форму результата: объяснение, категорию или структурированную запись.
- Качество ответов и разнообразие задач в обучающих данных влияют на перенос.
- Параметры меняются; это отличается от добавления примеров в один пользовательский запрос.

Обучение по предпочтениям

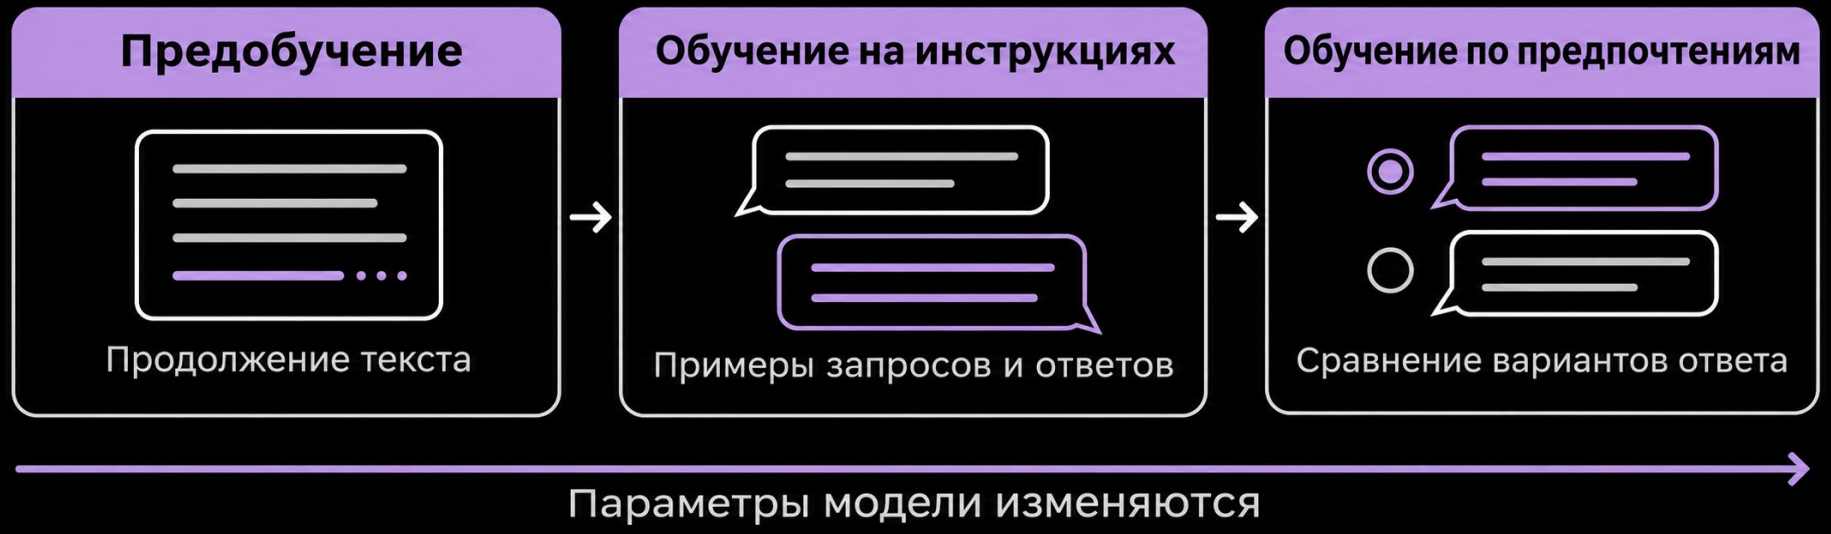
- Для одного запроса сравнивают несколько вариантов ответа и задают предпочтение.
- Учебная процедура стремится увеличить вероятность более подходящего поведения.
- Предпочтения отражают выбранные критерии и могут содержать ошибки или разногласия.
- Полезность, безопасность, стиль и фактическая точность требуют отдельных проверок.

Сравнение ответов человеком



Несколько ответов ранжируют по предпочтению. На схеме показано обучение модели оценки; это один из подходов к использованию предпочтений.

Этапы подготовки модели



- Предобучение, инструкции и предпочтения решают разные учебные задачи.
- Конкретная модель может использовать дополнительные этапы и другие последовательности.
- После обучения качество проверяют на независимых прикладных примерах.

Семейства больших языковых моделей

Семейство	Представитель для разбора	Публикация
GPT	GPT-3	2020
Llama	Llama 3	2024
Mistral	Mistral 7B	2023
Qwen	Qwen3	2025
DeepSeek	DeepSeek-V3	2024

- Это опубликованные учебные примеры, а не перечень последних версий или рейтинг качества.

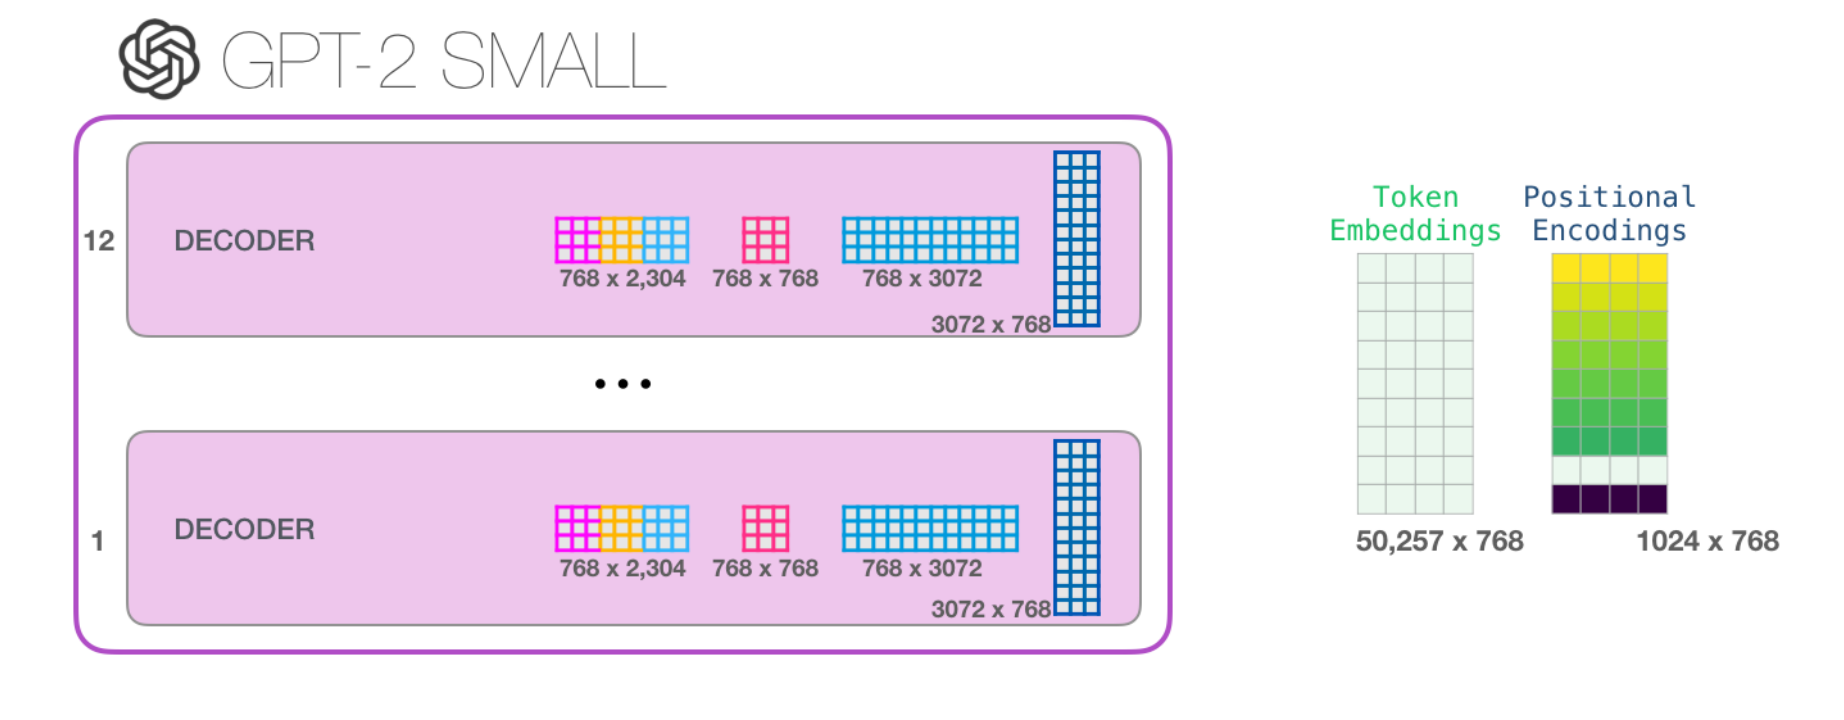
Масштабирование и примеры в контексте

- Работа о GPT-3 показала выполнение ряда задач по инструкции и примерам без обновления весов для каждой задачи.
- Обучающая цель связана с авторегрессионным продолжением текста.
- Результат зависит от формулировки, набора примеров и способа оценки.
- Название семейства не определяет точную версию, доступные функции и условия её применения.

Модели с доступными весами

- Семейство Llama иллюстрирует использование опубликованных весов для собственного применения и адаптации.
- Доступ к весам позволяет выбирать среду запуска и исследовать модель при соблюдении её условий использования.
- Существуют базовые и адаптированные варианты; их поведение и формат входа различаются.
- Лицензия, поддержка языка и требования к памяти проверяются для конкретного выпуска.

Веса внутри языковой модели



У разных блоков свои параметры. Опубликованные веса позволяют загрузить конкретную обученную модель в собственной среде.

Компактные модели и эффективность

- Mistral 7B — пример модели, где архитектурные и вычислительные решения важны наряду с числом параметров.
- В работе обсуждаются механизмы внимания, направленные на более эффективное применение.
- Меньший размер может снижать требования к ресурсам, но качество зависит от задачи и данных.
- Сравнение должно учитывать задержку, память, допустимую длину и качество на русском языке.

Многоязычные модели

- Семейство Qwen включает модели для работы с разными языками и видами задач.
- В отчёте Qwen3 представлены как плотные варианты, так и варианты со смесью экспертов.
- Поддержка русского языка требует проверки терминологии, формата ответа и устойчивости к ошибкам.
- Выбор версии включает размер, режим применения, лицензию и вычислительные ограничения.

Смесь экспертов

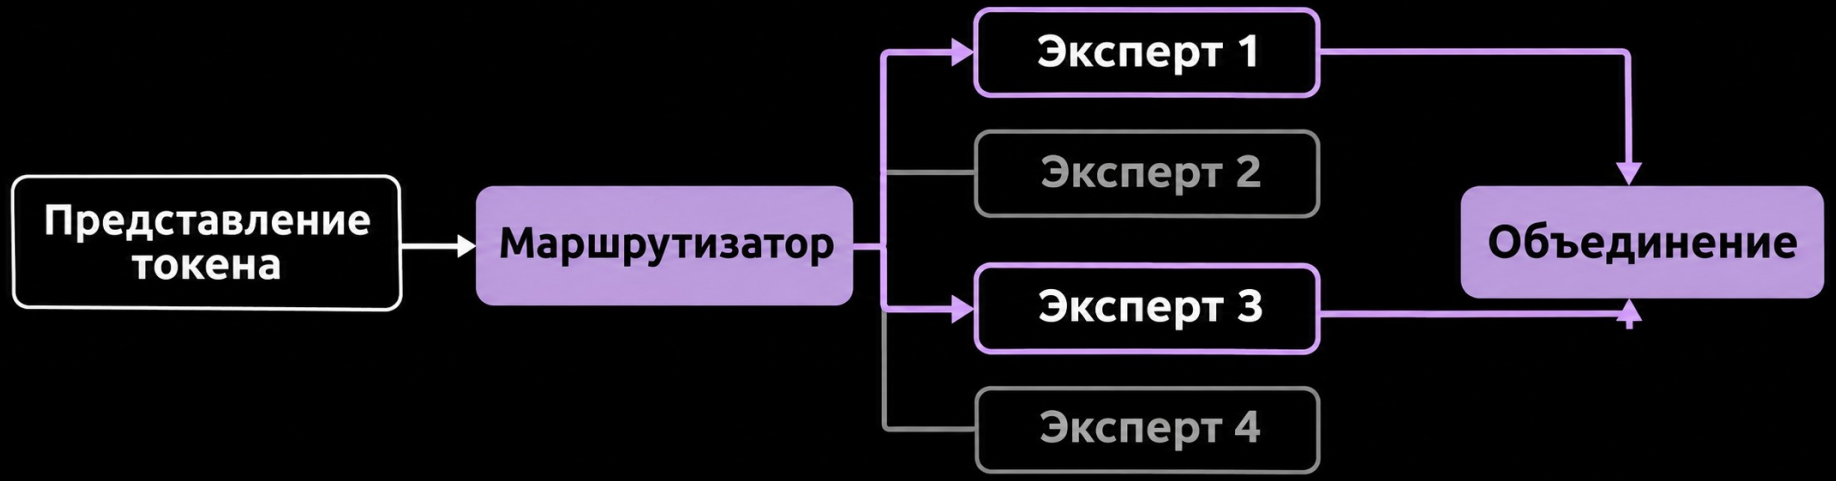


Иллюстрация: выбраны два эксперта из четырёх

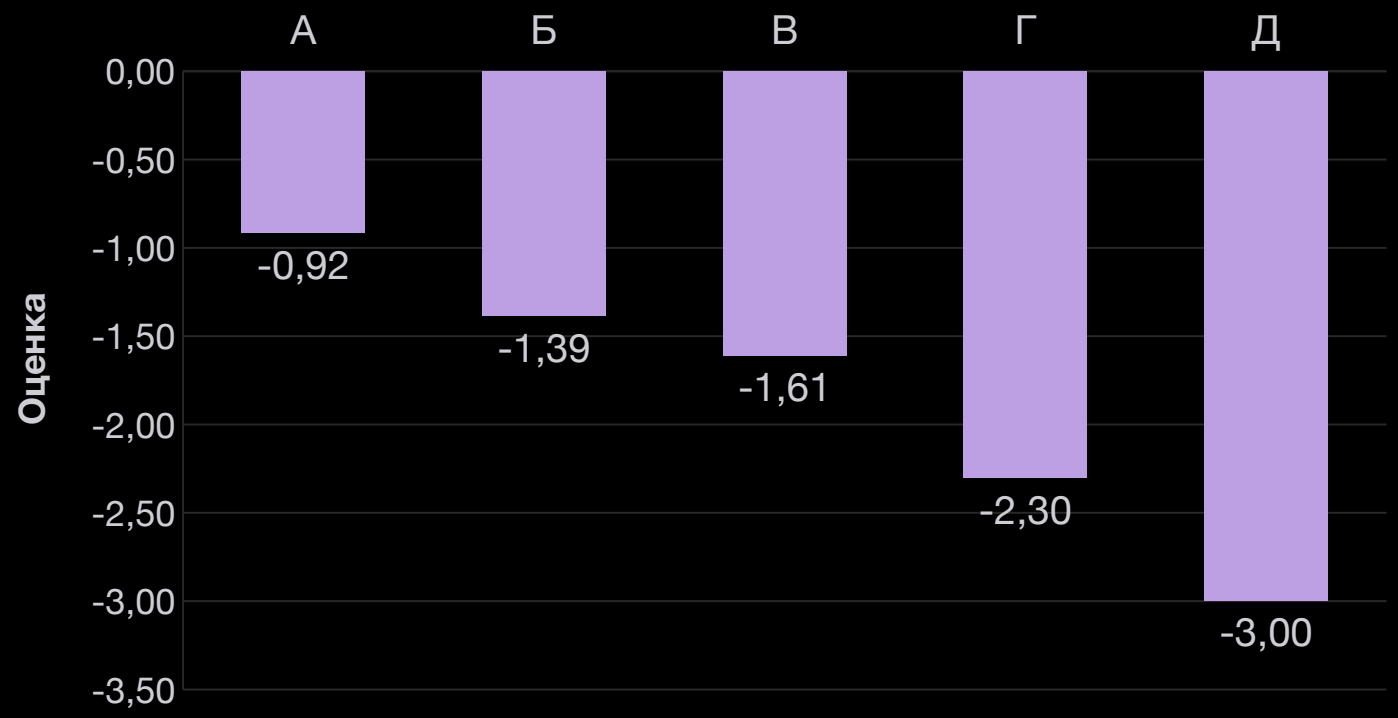
- В некоторых слоях маршрутизатор выбирает часть экспертных модулей для текущего токена.
- Общее число параметров и число активных параметров — разные величины.
- DeepSeek-V3 — пример такой архитектуры; эксперты являются вычислительными модулями, а не отдельными агентами.

Выбор конкретной версии модели

Проверяем	Почему это важно
Название и ревизию	Семейство содержит разные выпуски
Базовую или инструктивную версию	Меняются формат и поведение
Язык и задачу	Общая оценка не заменяет свои данные
Лицензию и ресурсы	Определяют допустимое применение

- Для сравнения сохраняют модель, формат входа и параметры генерации.
- Число параметров само по себе не определяет лучший вариант.

Оценки токенов перед выбором



- Логиты — числовые оценки выходного слоя; они не обязаны быть положительными.
- Преобразование в вероятности и алгоритм выбора — следующие этапы.
- На графике использованы учебные оценки ln(p) из нашего распределения.

Преобразование оценок в вероятности

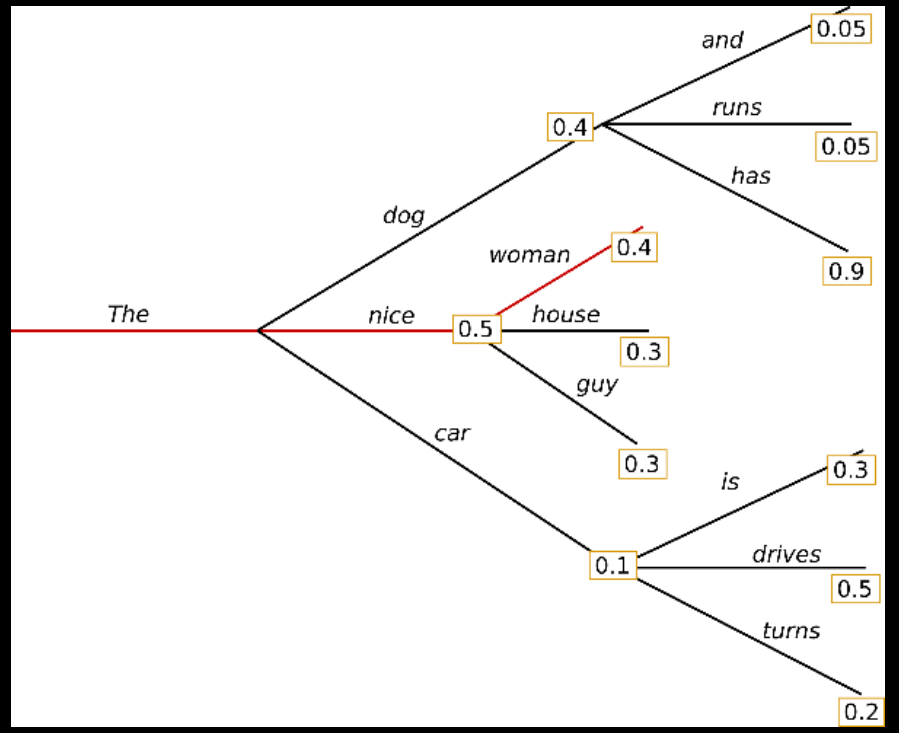
$$p_i = \exp(z_i) / \sum_j \exp(z_j)$$

- Softmax превращает оценки z_i в неотрицательные значения с суммой 1.
- Больший логит соответствует большей вероятности при прочих одинаковых условиях.
- Вероятность относится к продолжению токеном, а не к истинности всего ответа.
- Дополнительные ограничения могут изменить распределение перед выбором.

Жадный выбор

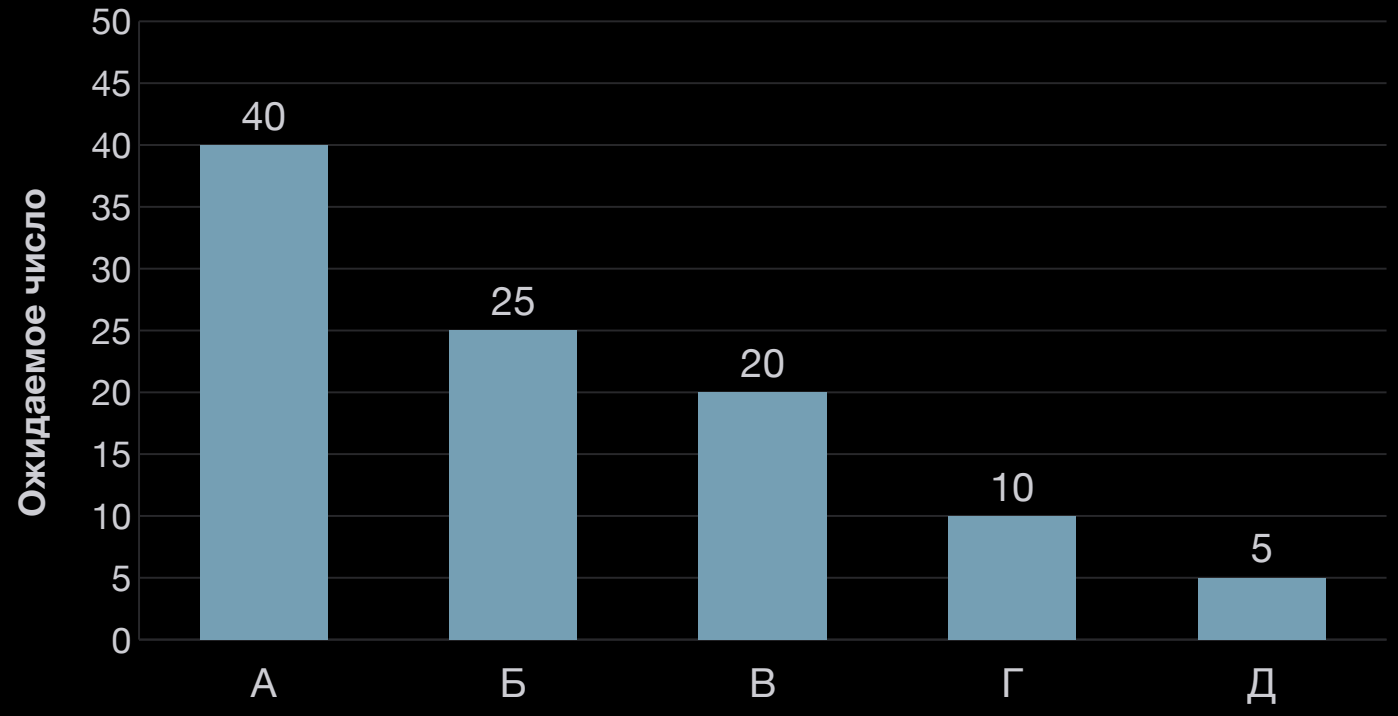
- На каждом шаге выбирается токен с наибольшей текущей вероятностью.
- При фиксированных вычислениях правило выбора не использует случайную выборку.
- Локально лучший токен не гарантирует лучшее полное продолжение.
- Повторяемость и фактическая правильность — разные свойства результата.

Пример жадного выбора



Красный путь выбирает максимальную вероятность на каждом шаге: 0,5, затем 0,4. Вероятность выбранного продолжения равна 0,20.

Случайная выборка продолжения



- Токен выбирается случайно с учётом вероятностей, а не обязательно по максимуму.
- Более вероятные кандидаты чаще выбираются при многократном повторении этого шага.
- Разные ответы не доказывают разнообразия фактов: меняется выбор продолжения.

Температура распределения

$$p_i(T) = \exp(z_i / T) / \sum_j \exp(z_j / T), \quad T > 0$$

- Меньшая температура концентрирует массу около более высоких оценок.
- Большая температура делает распределение более равномерным.
- Порядок логитов при положительной температуре сохраняется.
- Температура управляет выборкой, но не проверяет факты и не добавляет знания.

Числовой пример температуры



- При T=0,5 ведущий кандидат усиливается, при T=2 различия сглаживаются.
- Все столбцы рассчитаны из одного учебного распределения.
- Чтобы изучать влияние температуры, остальные настройки фиксируют.

Ограничение числа кандидатов

Кандидат	Исходная вероятность	После top-k = 3
А	0,40	0,471
Б	0,25	0,294
В	0,20	0,235
Г	0,10	0
Д	0,05	0

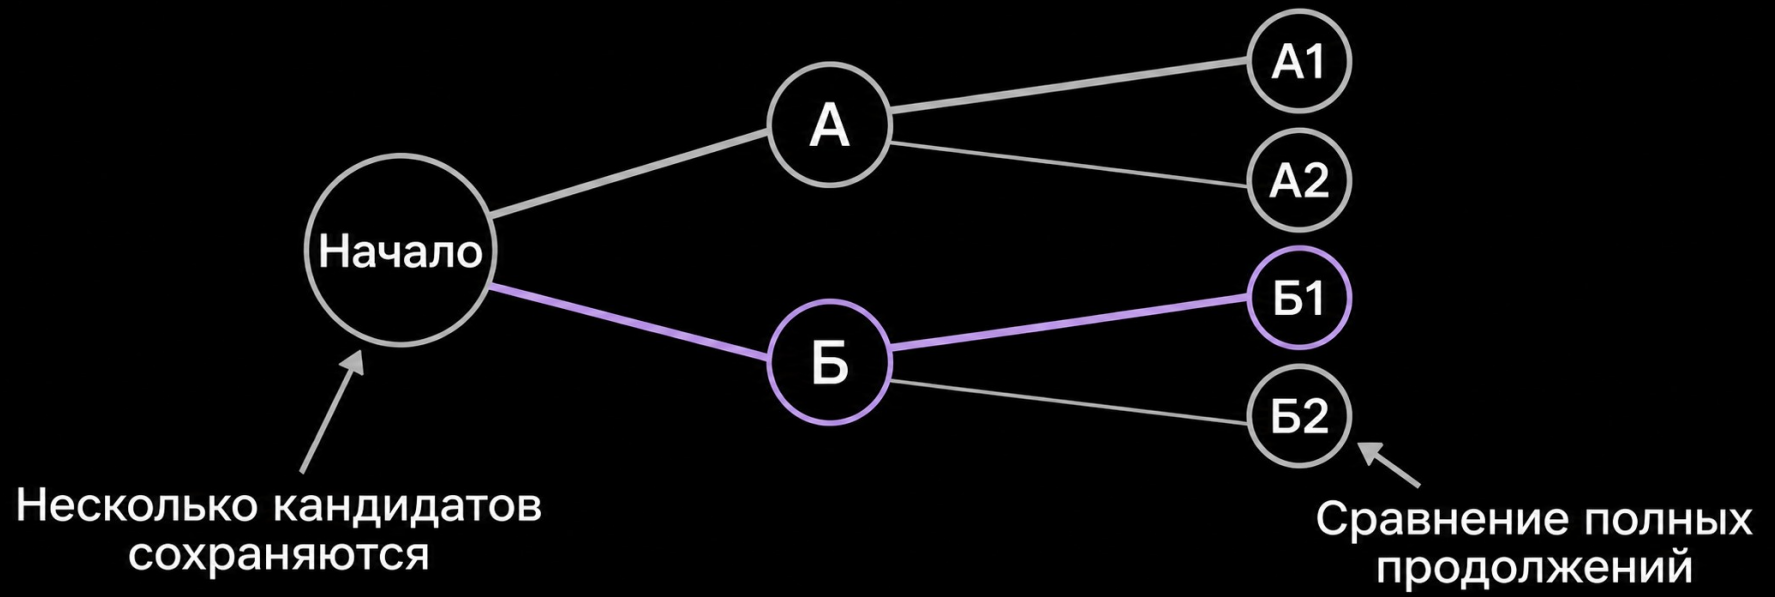
- Оставляем три наиболее вероятных токена и нормируем их суммарную массу 0,85.
- Выборка выполняется среди оставшихся; параметр k не задаёт длину ответа.

Ограничение накопленной вероятности

Кандидат	Вероятность	Накопленная сумма
А	0,40	0,40
Б	0,25	0,65
В	0,20	0,85
Г	0,10	0,95
Д	0,05	1,00

- При top-p = 0,8 выбираем минимальный префикс с суммой не меньше 0,8: А, Б и В.
- В отличие от top-k, число оставшихся кандидатов зависит от формы распределения.

Лучевой поиск



- На каждом шаге сохраняются несколько лучших частичных продолжений.
- Сравниваются накопленные оценки последовательностей по заданному правилу.
- Ширина луча увеличивает вычисления; ограниченный поиск не гарантирует глобальный оптимум.

Локальный и полный выбор

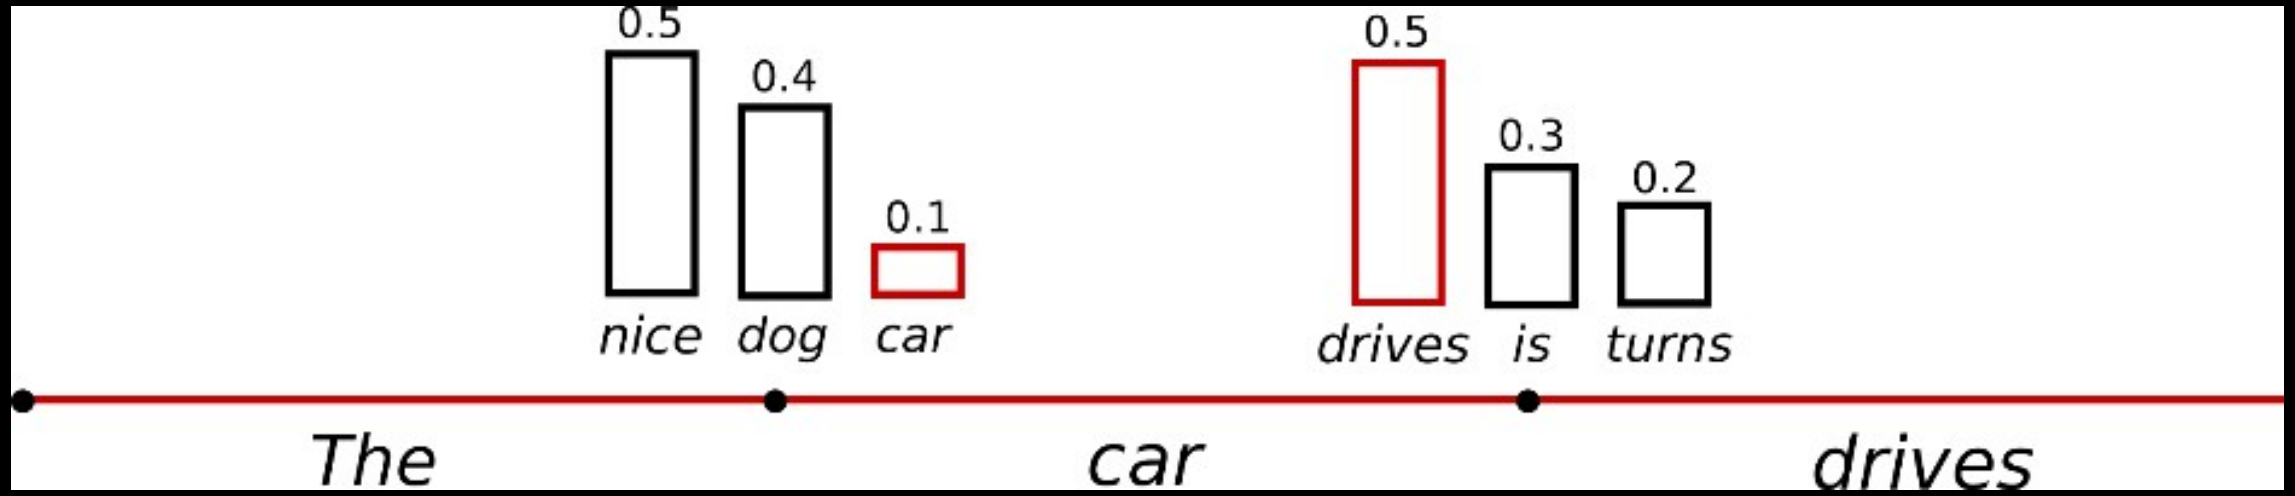
Продолжение	Расчёт	Вероятность
А → А1	0,6 × 0,51	0,306
А → А2	0,6 × 0,49	0,294
Б → Б1	0,4 × 0,90	0,360
Б → Б2	0,4 × 0,10	0,040

- Жадный первый шаг выбирает А, хотя лучшее полное продолжение в примере — Б → Б1.
- Сравниваются последовательности одинаковой длины; все числа условные.

Параметры и повторяемость генерации

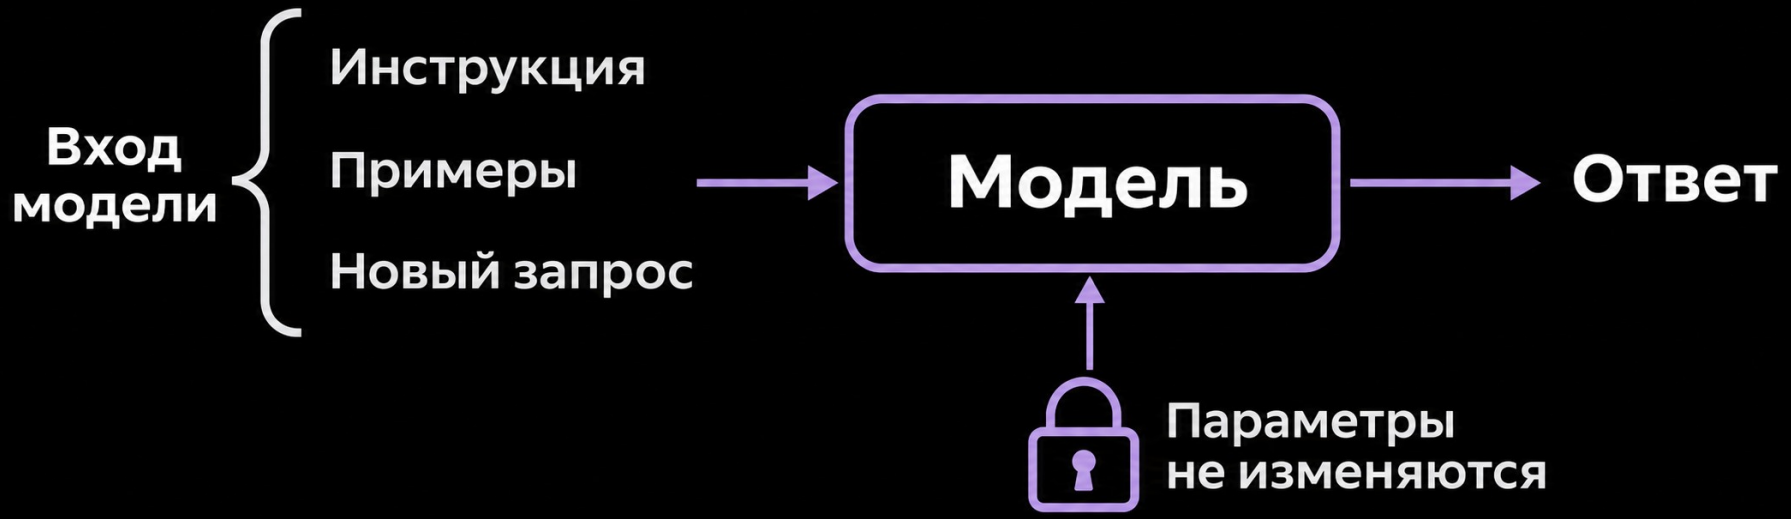
- Фиксируют модель и ревизию, входной текст, шаблон диалога и доступные параметры выбора.
- Лимит новых токенов ограничивает объём ответа, но не задаёт его смысловую полноту.
- При случайной выборке полезны несколько повторений; один удачный ответ не описывает качество.
- Набор параметров и поведение seed различаются между библиотеками и сервисами.

Случайная выборка продолжения



При выборке возможен токен, который не имеет максимальной вероятности. На схеме показан один допустимый путь, а не гарантированный ответ.

Выполнение задачи по контексту



- Инструкция и примеры задают требуемое поведение в текущем входе.
- Параметры модели при обычном применении не обновляются.
- Это обучение на примерах в контексте, а не дообучение весов.

Постановка без примеров

Часть запроса	Содержание
Инструкция	Выбери: Оплата, Доставка, Возврат или Прочее
Формат	Верни только название категории
Новый текст	После отмены заказа деньги не вернулись
Ожидаемый ответ	Возврат

- Модель получает описание задачи без демонстраций правильного ответа.
- Пример авторский: ожидаемая категория не является результатом измеренного запуска.

Один пример правильного ответа

Часть запроса	Содержание
Инструкция	Используй тот же набор четырёх категорий
Пример	«Где мой заказ?» → Доставка
Новый текст	«После отмены деньги не вернулись» →
Ожидаемый ответ	Возврат

- Один пример показывает соответствие входа и ответа, а также желаемое оформление.
- Он не описывает все границы классов и может оказаться нерепрезентативным.

Несколько примеров задачи

Текст примера	Категория
Где мой заказ?	Доставка
Оплата не проходит	Оплата
Когда вернут деньги после отмены?	Возврат
Как изменить язык интерфейса?	Прочее

- Примеры покрывают разные категории и помогают показать правило.
- Копии тестовых заданий не подходят для независимой оценки.
- Число примеров ограничено контекстом и не гарантирует монотонного роста качества.

Выбор и порядок примеров

- Примеры должны соответствовать задаче, иметь согласованные метки и понятный формат.
- Состав и порядок могут влиять на ответ, поэтому их фиксируют в сравнении.
- Проверяют новые формулировки, отрицания, редкие случаи и сообщения вне области.
- Изменение контекста не заменяет обучение модели и не создаёт постоянного знания в её весах.

Обучение и примеры в контексте



Горизонтальная стрелка обозначает предобучение. Вертикальные — использование примеров внутри запроса без изменения весов. Схема из работы о GPT-3, 2020.

Ограничения и проверка результата

- Связный ответ может содержать вымышленные сведения, пропущенные условия или неверные числа.
- Модель ограничена доступным контекстом и закономерностями своего обучения.
- Проверка включает соответствие задаче, фактическую опору, формат и устойчивость к переформулировкам.
- При недостатке сведений полезно предусмотреть уточнение или отказ от необоснованного ответа.

Контрольные вопросы

- Чем отличается вероятность следующего токена от вероятности истинности утверждения?
- Почему при обучении доступны все целевые токены, но причинная маска всё равно нужна?
- Чем температура отличается от ограничения top-k и top-p?
- В каком случае меняются веса: при добавлении примеров в запрос или при дообучении?
- Что нужно фиксировать, чтобы сравнить модели и параметры на семинаре?

Материалы и подготовка к семинару

- На семинаре: вызов модели, изменение параметров генерации и сравнение ответов на одной задаче.

YSDA NLP course

Предсказание и примеры в контексте

Масштабирование и вычислительный бюджет

Обучение выполнению инструкций

Стратегии генерации